AI Admission Assistant

Trợ lý AI hỗ trợ tuyển sinh thông minh

Nhóm 16

Tháng 4, 2026

Giới thiệu

Hệ thống RAG (Retrieval-Augmented Generation) giúp tra cứu quy chế, điểm chuẩn và học phí một cách nhanh chóng, chính xác

Công nghệ	RAG + AI
Nền tảng	Public Cloud
Mục tiêu	Enterprise Solution

Trước

Tiếp

Hiểu bài toán và bối cảnh Enterprise

Use case & User

Xây dựng trợ lý AI (RAG) hỗ trợ tra cứu quy chế, điểm chuẩn, học phí cho học sinh lớp 12, phụ huynh và cán bộ tư vấn

Dữ liệu

Quy chế tuyển sinh (PDF/Web), điểm chuẩn lịch sử và thông tin cá nhân từ CRM

Ràng buộc Enterprise

- Giải quyết tình trạng quá tải kênh tư vấn vào mùa cao điểm (tháng 4 - tháng 7)
- Tuân thủ Nghị định 13 về bảo vệ dữ liệu cá nhân (mức độ nhạy cảm CAO)
- Đảm bảo tính chính xác tuyệt đối và phải có trích dẫn nguồn gốc tài liệu

Trước

Tiếp

Lựa chọn kiến trúc triển khai

Lựa chọn

Public Cloud (kết hợp Hybrid Cloud nếu cần kết nối CRM nội bộ)

Logic lựa chọn

Tính co giãn (Elasticity)

Khả năng xử lý lưu lượng truy cập tăng đột biến gấp 100 lần (từ 500 lên 50.000 req/ngày)

Tốc độ

Tận dụng AI Managed Services (Gemini/OpenAI API) để triển khai nhanh

Trade-off

Đánh đổi giữa chi phí token cao của RAG để đổi lấy độ chính xác và tốc độ phản hồi tức thì

Phân tích chi phí - Cost Analysis

Các lớp chi phí

Compute, Storage (Vector DB), AI Token, Human Review và Maintenance

Dự toán MVP

$72/tháng

Chi phí ẩn

Phí duy trì Vector Database và chi phí nhân sự dán nhãn (Ground-truth labeling) để đánh giá chất lượng

Rủi ro chi phí

Token có thể tăng x3-x5 nếu người dùng đặt câu hỏi phức tạp cần nạp nhiều tài liệu

Chi tiết Chi phí theo Giai đoạn

Lớp Chi phí	Giai đoạn MVP (500 req/ngày)	Giai đoạn Growth (50k req/ngày)	Giải trình
LLM Token (AI)	$2 / tháng	$210 / tháng	Chi phí biến đổi theo traffic.
Vector Database	$45 / tháng	$150 / tháng	Lưu trữ & Tìm kiếm tài liệu quy chế (Pinecone/Milvus).
Logging & Monitor	$10 / tháng	$50 / tháng	Ghi lại lịch sử hội thoại để hậu kiểm.
Compute & Hosting	$15 / tháng	$150 / tháng	Server chạy Backend, Frontend & Auto-scaling.
Human Review	$0 (Nhóm tự làm)	$1,500 / tháng	01 nhân sự phụ trách hiệu đính thông tin & cập nhật quy chế.
TỔNG CỘNG	~$72 / tháng	~$2,060 / tháng	~50 triệu VNĐ/tháng mùa cao điểm

MVP Stage

~$72 / tháng

500 requests/ngày

Growth Stage

~$2,060 / tháng

50,000 requests/ngày - Mùa cao điểm

Tối ưu chi phí - Cost Optimization

Chiến lược	Lợi ích & Tiết kiệm	Đánh đổi
Semantic Caching	Giảm 40-60% phí Token; phản hồi tức thì	Có thể trả về thông tin cũ nếu cache chưa cập nhật
Model Routing	Tối ưu chi phí bằng cách dùng model rẻ (Flash) cho hội thoại thông thường	Tăng nhẹ độ trễ (latency) do bước phân loại đầu vào
Context Caching	Giảm chi phí nạp lại các bộ quy chế dày	Chỉ khả dụng trên một số nhà cung cấp nhất định

Độ tin cậy và Khả năng mở rộng

Kịch bản ứng phó với lỗi hệ thống

Traffic tăng đột biến

→ Sử dụng Auto-scaling Serverless và Message Queue để điều phối

Lỗi Provider API

→ Tự động chuyển sang mô hình dự phòng (OpenAI/Local Model) hoặc trả về FAQ tĩnh

Phản hồi chậm

→ Áp dụng Streaming và cập nhật giao diện thông báo tiến trình cho người dùng

Chỉ số theo dõi (Metrics)

Citation Rate (độ chính xác), Latency, Token Usage và Error Rate